


書報討論筆記 | 交通風險預測


題目: Urban Sensing and its Smart Application on Predicting Road Traffic Risks

講者:胡誌麟

日期: 2026/5/5



此次主題是「都市感測與道路交通風險預測的智慧應用」。核心概念是利用城市中各種感測資料，例如交通事故、車流量、天氣、道路型態與時間資訊，透過資料處理與深度學習模型，預測不同地區、不同時間的道路交通風險，幫助交通管理或事故預防。



行動群眾感測（MCS）是都市感測的一種重要方法，透過大量使用者的手機、行動裝置或感測設備收集資料。它可以應用在交通監控、物流追蹤、環境監測、災害回報、社交互動、疫情監測等領域。這種方式的優點是資料來源廣泛、即時性高，適合用來觀察城市中的動態變化。

The image is a screenshot of a presentation slide titled "MCS: Definition and Formation". The slide is displayed within a window that has a green title bar with "Help" and a search bar at the top. The slide content is as follows:

MCS: Definition and Formation



- ❖ An MCS system includes two roles, basically
 - ▶ A **service provider** recruits mobile users to operate crowdsensing tasks.
 - ▶ **Mobile users**, a.k.a. participants, acquire sensing data and continue task executions in a participatory like "virtual teamwork."
- ❖ In MCS communities, however, task executions often incur many **resource costs and privacy risks on service provision**.
 - ▶ **Resource costs** — Mobile users expend limited resources, e.g., energy, computation, storage, and bandwidth, which are critical to mobile devices themselves
 - ▶ **Privacy risks** — Collected data usually contain individuals' application data together with the spatial and temporal information of user movement.
Privacy threats arise from the leak of user workplaces, profiles and behavioral data

At the bottom left of the slide is the "NCS" logo, and at the bottom right is the number "6".

MCS 系統主要包含兩個角色：服務提供者與行動使用者。服務提供者負責招募使用者執行感測任務，而行動使用者則負責蒐集資料並持續參與任務。然而，在 MCS 系統中也會產生資源成本與隱私風險，例如使用者需要消耗手機電量、運算能力、儲存空間與網路頻寬；同時，收集到的資料可能包含位置、移動軌跡、個人行為等敏感資訊，因此隱私保護也是重要議題。

Spatio-Temporal Issues

- ❖ **Traffic sensing data** in IoT, ITS and MCS exhibit spatial and temporal correlations, as well as high complexity of spatio-temporal dynamics.
 - **Spatial** domain - traffic conditions at neighboring locations influence each other.
 - **Temporal** domain - traffic conditions are related across different time segments.
- ❖ **Spatial and temporal Issues often co-exist together**, complicating the traffic flow analysis and traffic risk prediction



交通感測資料具有明顯的空間與時間特性。空間上，相鄰道路或鄰近區域的交通狀況會互相影響；時間上，不同時段的交通流量也存在關聯，例如上班時間與下班時間會出現不同的車流型態。因為空間與時間因素通常會同時存在，所以在分析交通流量與預測交通風險時，必須同時考慮時空關聯，否則模型可能無法準確掌握真實交通狀況。

Step I: Data Preprocessing

- ❖ Prerequisite for handling partial data loss and cleaning unfit, abnormal, or incomplete data.
- ❖ Data quality supervision methods
 - ▶ Missing value imputation
 - ▶ K-nearest neighbor imputation
- ❖ Dividing the data into $I \times J$ grids on the map




Weather, calendar, road patterns



Data Type 1 • Meteorology *per hour*

- Temperature
- Hourly rainfall
- Relative humidity
- Air pressure
- Maximum wind speed
- Timestamp
- Holiday
- Road type

Traffic flow, accidents




Data Type 2

- Traffic flow *per grid*
- Traffic speed *per grid*
- Number of accidents *per grid*
- All above values are calculated in each unit time

在進行交通風險預測前，資料前處理是必要步驟。原始資料可能會有缺失值、異常值或不完整資料，因此需要透過資料清理與補值方法改善資料品質，例如 Missing value imputation 或 K-nearest neighbor imputation。接著會把地圖切分成多個網格，並在每個網格與單位時間內計算相關特徵，例如天氣資料、時間戳記、假日、道路類型、車流量、車速與事故數量，讓模型可以用統一格式分析不同區域的風險。

CarView's Deep Learning



CarView 的深度學習架構主要分成幾個步驟。首先進行資料前處理，將天氣、日曆、道路型態、交通流量與事故資料整理成模型可使用的格式。接著使用 Feature Embedding 將資料轉換成特徵表示，再透過 CNN 分析空間特徵，透過 LSTM 分析時間序列變化。最後模型會結合不同特徵，輸出交通風險預測結果，通常以地圖熱區或網格風險值的形式呈現。

Step 4: Element-Wise product

- Given with F_s and F_t , we apply **Hadamard Product** to calculate the outcome.


4 Element-Wise Product

Hadamard Product

Fully Connected Layer

$$\begin{matrix} F_s \\ \begin{bmatrix} f_{s_{1,1}} & \cdots & f_{s_{1,d}} \\ \vdots & \ddots & \vdots \\ f_{s_{N,1}} & \cdots & f_{s_{N,d}} \end{bmatrix} \end{matrix} \odot \begin{matrix} F_t \\ \begin{bmatrix} f_{t_{1,1}} & \cdots & f_{t_{1,d}} \\ \vdots & \ddots & \vdots \\ f_{t_{N,1}} & \cdots & f_{t_{N,d}} \end{bmatrix} \end{matrix} = \begin{matrix} \text{Hadamard}(F_s, F_t) \\ \begin{bmatrix} f_{s_{1,1}} \cdot f_{t_{1,1}} & \cdots & f_{s_{1,d}} \cdot f_{t_{1,d}} \\ \vdots & \ddots & \vdots \\ f_{s_{N,1}} \cdot f_{t_{N,1}} & \cdots & f_{s_{N,d}} \cdot f_{t_{N,d}} \end{bmatrix} \end{matrix}$$

- Pass through activation function π , and then a fully connected layer is applied to get the output.




To reduce the training cost and speed up the training process, the ReLU function is used as the activation function.

在模型中，Element-Wise Product 是用來融合不同特徵的重要步驟。簡報中使用 Hadamard Product，將兩組特徵矩陣 F_s 與 F_t 對應位置相乘，讓空間特徵與時間特徵可以結合。之後再經過 activation function 與 fully connected layer，產生最後的交通風險輸出。簡報也提到使用 ReLU 作為 activation function，目的是降低訓練成本並加快訓練速度。

Experimental Results (2025)

❖ Training data categories of Taoyuan Municipality (2023)



實驗資料以桃園市 2023 年的資料為基礎，包含道路交通事故、車輛偵測器統計資料與天氣資料。資料內容包含車禍紀錄、交通量、溫度、濕度、壓力與降雨等資訊，其中事故資料有 109,148 筆，車輛偵測器資料有 232,906 筆，天氣資料有 8,760 筆。研究區域以桃園區為主，並將地圖切成不同大小的網格，例如 100m、500m、1000m，用來觀察不同空間解析度下的交通風險分布。